

# Análise dos Microdados do ENEM: Desigualdade Socioeconômica e Desempenho Educacional no Brasil

**Disciplina:** Análise de Dados  
**Instituição:** Universidade Federal da Paraíba (UFPB)  
**Data:** Junho de 2026

- Equipe:**
- Augusto Blois Almeida Barbosa
  - Pedro Flávio Nogueira Ribeiro de Luna

## 1. Problema e Justificativa de Relevância

O Exame Nacional do Ensino Médio (ENEM) é o maior exame educacional do Brasil, com mais de 3 milhões de inscritos por edição. Além de ser a principal porta de entrada para o ensino superior via SISU, o exame coleta, por questionário socioeconômico, informações detalhadas sobre o contexto de vida de cada participante: renda familiar, raça/cor, escolaridade dos pais, acesso à internet, tipo de escola, entre outros.

**O problema central:** a educação brasileira reproduz desigualdades estruturais. Candidatos de maior renda, filhos de pais com ensino superior, provenientes de escolas privadas e de regiões mais ricas sistematicamente superam os demais. A magnitude exata dessas diferenças, sua variação ao longo do tempo e os fatores que mais as explicam seguem pouco explorados de forma integrada e visual.

**Justificativa:** os microdados do ENEM combinam indicadores socioeconômicos com notas em cinco áreas de conhecimento, constituindo uma das fontes mais abrangentes para o estudo da desigualdade educacional em escala nacional. O recorte temporal 2022–2023 permite análise comparativa recente.

**O que este projeto entrega:** quantificação, visualização e comunicação dessas disparidades, identificando quais variáveis socioeconômicas exercem maior influência sobre o desempenho, com atenção especial ao contexto nordestino.

## 2. Público-alvo e Tomador de Decisão

| Perfil                                                          | Uso esperado do produto                                             |
|-----------------------------------------------------------------|---------------------------------------------------------------------|
| Gestores de políticas educacionais (MEC, secretarias estaduais) | Identificar regiões e perfis que demandam intervenção prioritária   |
| Pesquisadores e docentes de educação                            | Base analítica para estudos sobre desigualdade escolar              |
| Equipes pedagógicas de escolas públicas                         | Contextualizar desempenho de alunos frente ao perfil socioeconômico |
| Jornalistas de dados e comunicadores                            | Narrativas visuais sobre equidade educacional                       |

O tomador de decisão primário é o **gestor de política pública educacional**: alguém que precisa de evidências quantitativas para priorizar investimentos e ações afirmativas.

### 3. Perguntas Analíticas e Hipóteses Iniciais

#### P1 — Renda e desempenho

Qual a relação entre faixa de renda familiar e nota média nas cinco áreas?

*Hipótese*: relação positiva e aproximadamente monotônica, com retornos decrescentes nas faixas mais altas (acima de 5 SM). O efeito da renda deve ser mais pronunciado em Matemática que em Redação.

#### P2 — Escola pública vs. privada

Qual o gap médio entre candidatos de escolas públicas e privadas? Esse gap variou entre 2022 e 2023?

*Hipótese*: gap persistente de 80–120 pontos em média. Sem variação significativa entre os dois anos, dado que políticas estruturais não mudam em um ciclo anual.

#### P3 — Disparidade regional

Candidatos do Nordeste apresentam notas sistematicamente mais baixas que do Sul/Sudeste? A disparidade persiste controlando por renda e tipo de escola?

*Hipótese*: disparidade regional existe, mas é parcialmente explicada pela composição socioeconômica. Controlando por renda e tipo de escola, o efeito regional residual deve ser menor que 30 pontos.

#### P4 — Preditores combinados

Quais variáveis socioeconômicas, em conjunto, melhor predizem o desempenho?

*Hipótese*: renda familiar e tipo de escola serão os dois preditores mais fortes. Escolaridade dos pais contribuirá de forma independente. Um modelo simples (regressão linear) deve capturar  $R^2 \geq 0,30$ .

#### P5 — Perfil da nota 1000 na Redação

Qual o perfil socioeconômico dos candidatos com nota máxima na Redação?

*Hipótese*: concentração em escolas privadas e renda acima de 3 SM, mas com maior diversidade regional que o grupo de alto desempenho geral — a Redação é a área com menor dependência de insumos materiais.

### 4. Fontes de Dados e Viabilidade

**Base principal**: Microdados do ENEM — INEP

**URL**: <https://www.gov.br/inep/pt-br/aceso-a-informacao/dados-abertos/microdados/enem>

**Edições**: 2022 e 2023

**Formato**: CSV compactado (.zip), dicionário de variáveis incluso

**Tamanho estimado**: 2–4 GB por edição (descompactado)

**Acesso**: público, irrestrito, sem autenticação

**Variáveis de interesse**:

| Variável                                                        | Descrição                      |
|-----------------------------------------------------------------|--------------------------------|
| NU_NOTA_MT, NU_NOTA_LC, NU_NOTA_CN, NU_NOTA_CH, NU_NOTA_REDACAO | Notas por área                 |
| Q006                                                            | Faixa de renda familiar mensal |

| Variável           | Descrição                           |
|--------------------|-------------------------------------|
| Q001, Q002         | Escolaridade do pai e da mãe        |
| TP_ESCOLA          | Tipo de escola<br>(pública/privada) |
| SG_UF_PROVA        | Unidade da Federação                |
| TP_COR_RACA        | Raça/cor autodeclarada              |
| IN_ACESSO_INTERNET | Acesso à internet em casa           |
| NU_ANO             | Ano da edição                       |

**Avaliação de viabilidade:** confirmada. Dados amplamente utilizados em pesquisas acadêmicas, com documentação completa e histórico de disponibilidade ininterrupta. Risco de indisponibilidade: nulo.

## 5. Produto Final

Dois entregáveis complementares:

### 5.1 Dashboard Interativo

Desenvolvido em Python com Streamlit. Funcionalidades:

- Filtro por ano, UF, tipo de escola, faixa de renda
- Distribuição de notas por área
- Comparação entre grupos (público vs. privado; Nordeste vs. Sul/Sudeste)
- Mapa coroplético com desempenho médio por estado
- Gráficos de correlação renda × nota

### 5.2 Relatório Técnico (PDF)

- Pipeline de dados (extração → limpeza → análise → visualização)
- Respostas às cinco perguntas analíticas com gráficos
- Resultados do modelo preditivo (P4) com métricas ( $R^2$ , MAE)
- Conclusões e limitações

## 6. Plano de Execução

| Etapa         | Atividade                                                                      | Prazo    |
|---------------|--------------------------------------------------------------------------------|----------|
| 1. Extração   | Download dos microdados 2022 e 2023; verificação de integridade                | Semana 1 |
| 2. Tratamento | Limpeza de ausentes; seleção e tipagem de variáveis; amostragem se necessário  | Semana 2 |
| 3. EDA        | Estatísticas descritivas; distribuições; correlações; comparações entre grupos | Semana 3 |

| Etapa              | Atividade                                   | Prazo       |
|--------------------|---------------------------------------------|-------------|
| 4.<br>Modelagem    | Modelo preditivo (P4); métricas $R^2$ e MAE | Semana<br>4 |
| 5.<br>Visualização | Dashboard Streamlit; gráficos do relatório  | Semana<br>5 |
| 6. Entrega         | Revisão; relatório técnico; submissão       | Semana<br>6 |

**Stack:** Python 3.11+, pandas, matplotlib/seaborn, scikit-learn, Streamlit, Jupyter Notebook.